

Evaluación Comparativa de Modelos de Riesgo Crediticio

Reporte Estadístico Académico e Inferencia de Modelos

Fecha:	13/07/2026	Origen de Datos:	PostgreSQL - Capa GOLD (Real)
Mejor Modelo:	LightGBM	Optimización:	F1-Score / AUC-ROC

1. Introducción y Metodología

El presente informe detalla la evaluación estadística de 5 algoritmos de aprendizaje automático para el modelado del riesgo crediticio (probabilidad de impago), utilizando la estructura del dataset histórico de Home Credit de Kaggle. La metodología implementa validación cruzada estratificada con 5 particiones (Stratified 5-Fold Cross Validation) para garantizar la robustez ante el desbalance de clases. Se entrenaron 3 modelos clásicos (Regresión Logística, Árbol de Decisión, Random Forest) y 2 de ensamble/híbridos basados en Boosting (XGBoost y LightGBM).

Justificación Académica del Formato del Modelo:


Para la implementación del backend de predicción en producción, se ha optado por exportar el modelo ganador en formato serializado **.pkl (Joblib)** en lugar del formato **.h5 (HDF5)**. La razón técnica fundamental radica en la naturaleza de los modelos: el formato HDF5 (.h5) fue diseñado para almacenar arquitecturas de Redes Neuronales Profundas (Keras o TensorFlow), donde se requiere guardar pesos tensoriales estructurados en múltiples capas y topologías complejas. Para algoritmos de Machine Learning tradicionales orientados a datos tabulares (especialmente árboles y ensambles de Boosting como LightGBM o XGBoost), el formato de serialización estándar de Python es .pkl a través de la biblioteca Joblib, ya que optimiza el guardado de los grafos estructurados de árboles sin sobrecarga innecesaria.

2. Tabla Comparativa de Rendimiento

Modelo	Acc	Prec	Rec	F1	AUC	MCC	Tiempo (s)
Regresión Logística	0.5910	0.1171	0.6216	0.1970	0.6435	0.1155	118.45
Árbol de Decisión	0.5943	0.1158	0.6066	0.1945	0.6357	0.1102	12.12
Random Forest	0.6215	0.1216	0.5927	0.2018	0.6505	0.1209	67.51
XGBoost	0.6332	0.1276	0.6070	0.2108	0.6644	0.1358	20.71
LightGBM	0.6356	0.1286	0.6083	0.2123	0.6650	0.1381	27.01

3. Análisis de Visualizaciones Gráficas

Curvas ROC Comparativas: Permite contrastar la tasa de verdaderos positivos (TPR) contra la tasa de falsos positivos (FPR) a diferentes umbrales de decisión.



Matriz de Confusión del Modelo Ganador (LightGBM): Visualiza la clasificación correcta e incorrecta de la muestra de prueba.



4. Validación de Modelos con Pruebas Estadísticas

Para comprobar rigurosamente si la diferencia entre los dos algoritmos con mejor desempeño (LightGBM y XGBoost) es estadísticamente significativa, se aplicó la prueba de **McNemar**. Dicha prueba analiza la simetría en la matriz de errores de clasificación de ambos modelos.

	XGBoost Correcto	XGBoost Incorrecto
LightGBM Correcto	37842	1247
LightGBM Incorrecto	1099	21315

Estadístico Chi-cuadrado:	9.2110
P-Valor (p-value):	0.002406
Diferencia Significativa ($\alpha = 0.05$):	SÍ es significativa (se rechaza H0)

Interpretación Estadística Académica:

El test de McNemar arrojó un p-valor menor que el nivel de significancia del 5% ($p < 0.05$), lo cual proporciona evidencia estadística suficiente para rechazar la hipótesis nula de igual tasa de error. Por ende, se concluye formalmente que existe una diferencia significativa en la precisión predictiva entre LightGBM y XGBoost, estableciendo a LightGBM como el clasificador estadísticamente superior.

5. Validación Cruzada e Inferencia de Estabilidad (Wilcoxon)

Para evaluar la consistencia del modelo frente a cambios en la muestra de entrenamiento, se analizaron las puntuaciones de AUC-ROC out-of-fold para cada uno de los 5 pliegues de la validación cruzada. Se aplicó el test estadístico robusto de **Wilcoxon Signed-Rank Test** comparando el ganador contra el benchmark clásico (**Random Forest**).

Pliegue (Fold)	AUC Random Forest (Benchmark)	AUC LightGBM (Ganador)
Pliegue 1	0.6594	0.6678
Pliegue 2	0.6523	0.6621
Pliegue 3	0.6522	0.6632
Pliegue 4	0.6558	0.6672
Pliegue 5	0.6525	0.6622

Estadístico de la Prueba:	0.0000
P-Valor (p-value):	0.062500
Diferencia Significativa ($\alpha = 0.05$):	NO es significativa (no se rechaza H0)

Interpretación Estadística Académica:

El test Wilcoxon Signed-Rank Test sobre los 5 pliegues de validación cruzada arrojó un p-valor mayor o igual a 0.05. Esto indica que no se dispone de suficiente evidencia para descartar la hipótesis nula, concluyendo que ambos modelos ofrecen un desempeño estadísticamente equivalente en términos de estabilidad de validación cruzada.